

# 컴퓨터비전개론

## Chap 1. Image Filtering

- separable filter
  - rank = 1
  - gaussian filter : input의 가운데 픽셀값을 강조하는 효과
  - sobel convoultion kernel
- : x\_dir(vertical edges), y\_dir(horizontal edges)

**x direction**

$$\begin{bmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} * \begin{bmatrix} 1 & 0 & -1 \end{bmatrix}$$

**y direction**

$$\begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix} * \begin{bmatrix} 1 & 2 & 1 \end{bmatrix}$$

- Image edges
- intensity가 급격히 변하는 곳
- gradient의 방향은 edge의 수직인 방향

### Computing Image Gradients



1. Select your favorite derivative filtering.

$$S_x = \begin{bmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{bmatrix} \quad S_y = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$$

2. Convolve with the image to compute derivatives.

$$\frac{\partial f}{\partial x} = S_x \otimes f \quad \frac{\partial f}{\partial y} = S_y \otimes f$$

3. Form the image gradient, and compute its direction and magnitude.

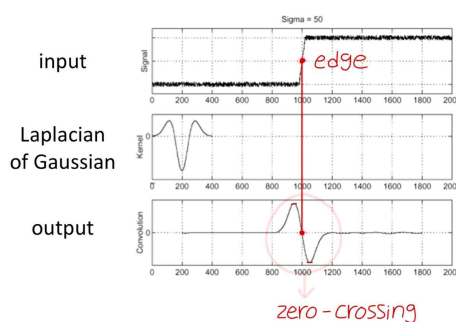

$$\nabla f = \left[ \frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right] \quad \theta = \tan^{-1} \left( \frac{\partial f / \partial y}{\partial f / \partial x} \right) \quad \|\nabla f\| = \sqrt{\left( \frac{\partial f}{\partial x} \right)^2 + \left( \frac{\partial f}{\partial y} \right)^2}$$

gradient                      direction                      magnitude


### • Canny Edge Detector

- ① compute x and y gradient
- ② find magnitude and orientation of gradient
- ③ non-maximum suppression
- ④ hysteresis thresholding

### • DoG(Derivative of Gaussian) vs LoG(Laplacian of Gaussian)



### ★ Laplacian을 DoG를 이용하여 근사하는 법



DoG는 입력영상에 Gaussian 필터를 점진적으로 적용하여 블러링(blurring)시킨 이미지들에서 인접 이미지들간의 차(subtraction) 영상을 의미하며 이론적으로는 LoG(Laplacian of Gaussian) 필터를 적용한 것과 거의 동일한 결과를 갖습니다.

## Chap 2. Image Pyramids

### • Aliasing

: sampling 시 서로 다른 신호를 구별할 수 없게 만드는 효과

- 원인

- ① sampling rate mismatch
- ② moire : object이 한 픽셀 중 R, G, B 한 곳에 집중되게 matching
- ③ temporal aliasing : FPS(frame per second)

### • Anti-Aliasing

- Oversample the signal : 한 픽셀에 여러번 sampling 한 후 평균값을 구함

- smooth ths signal : aliasing을 일으키는 요소를 제거, 이는 정보손실을 유발하지만 aliasing을 줄일 수 있음

### • Gaussian Image Pyramid

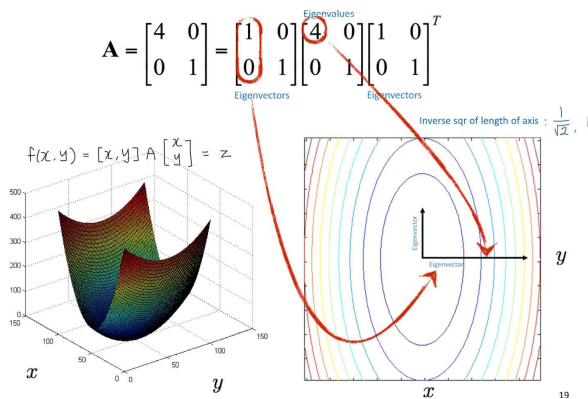
- 왜 필요한가? anti-aliasing 하기 위해 smoothing(gaussian filter) 후 delete(행, 열 삭제)하는데 반복 작업일 경우 오래 걸림
- mip map을 만들면 원래 용량의 4/3배 증가함
- 하지만 reconstruct를 하면 화질이 많이 떨어짐 -> super resolution을 해야함

### • Laplacian Image Pyramid

- 각 레벨에서 blurred image 대신에 residual을 남겨서 reconstruct할 때도 화질이 복원이 되도록 함

## Chap 3. Corner Detection

### • Paraboloid



### ★ Eigenvector & Eigenvalues

: 행렬 A를 선형변환으로 봤을 때, 선형변환 A에 의한 변환 결과가 자기 자신의 상수배가 되는 0이 아닌 벡터를 eigenvector라 하고 이 상수배 값을 eigenvalue라 한다.

- $\lambda$  : 행렬 A의 고유값
- $v$  : 행렬 A의  $\lambda$ 에 대한 고유벡터

$$Av = \lambda v \quad (1)$$

$$\begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix} = \lambda \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix}$$

### ★ Eigendecomposition ( only 정방행렬 )

행렬 A의 고유벡터들을 열벡터로 하는 행렬을 P, 고유값들을 대각원소로 하는 대각행렬을  $\Lambda$ 라 하면 다음 식이 성립

$$AP = P\Lambda$$

$A = P\Lambda P^{-1}$  : 행렬 A는 고유벡터들을 열벡터로 하는 행렬과 고유값을 대각원소로 하는 행렬의 곱으로 대각화 분해 가능

- eigendecomposition을 알면  $\det(A)$ , A의 거듭제곱, 역행렬, 대각합(trace), 행렬의 다항식을 쉽게 계산 가능
- 가능 조건

①  $n \times n$  정방행렬 A가 n개의 일차독립(linearly independent)인 고유벡터를 가져야 함.

②  $A^T = A$  (모든 i, j에 대해  $a_{ij} = a_{ji}$ )인 대칭행렬(symmetric matrix)

: 특히, 직교행렬로 대각화가 가능함

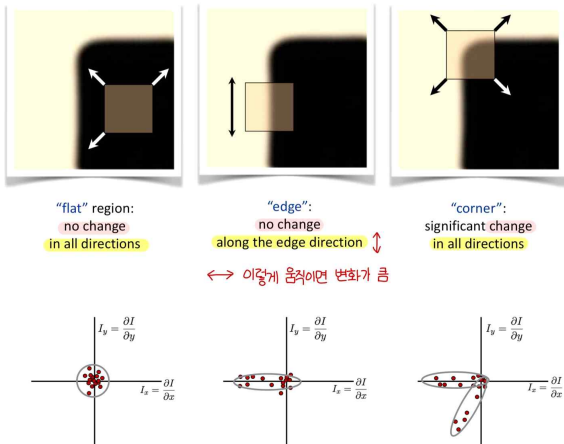
$$\begin{aligned} A &= P\Lambda P^{-1} \\ &= P\Lambda P^T \quad (24) \\ \text{단, } PP^T &= E \quad (P^{-1} = P^T) \end{aligned}$$

### ★ 직교행렬(orthogonal matrix)

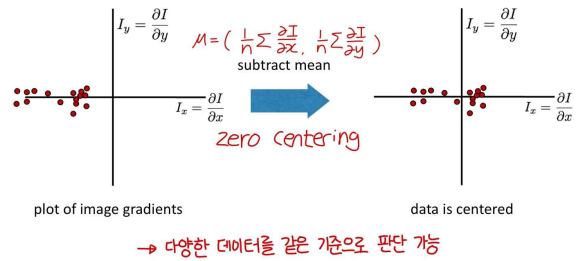
: 자신의 전치행렬(transpose)를 역행렬로 갖는 정방행렬으로 각각의 열벡터의 크기는 1이며 열벡터끼리의 곱은 0임.

• Harris Corner Detector ( only grayscale image )

① compute image gradients over small region



② subtract mean from each image gradient



★ Covariance Matrix

$$\text{Var}[X] = \begin{bmatrix} \text{Var}[X_1] & \text{Cov}[X_1, X_2] \\ \text{Cov}[X_2, X_1] & \text{Var}[X_2] \end{bmatrix}$$

- 분산 : x들이 평균을 중심으로 얼마나 흩어져 있는지
- 공분산 : x1, x2의 흩어진 정도가 어떤 상관관계를 가지고 흩어졌는지

③ compute the covariance matrix of gradient

$$\begin{bmatrix} \sum_{p \in P} I_x I_x & \sum_{p \in P} I_x I_y \\ \sum_{p \in P} I_y I_x & \sum_{p \in P} I_y I_y \end{bmatrix}$$

- why? change of intensity for the shift [u, v]을 구하기 위해서

$$E(u, v) = \sum_{(x,y)} w(x,y) [I(x+u, y+v) - I(x,y)]^2$$

Error function      Window function      Shifted intensity      Intensity

Window function  $W(x, y) =$  or Gaussian

1 in window, 0 outside      Gaussian

←  $I(x+u, y+v) \approx I(x,y) + I_x u + I_y v$  대입 ( Taylor Series )

$$= u^2 \sum_{(x,y)} w(x,y) I_x^2 + 2uv \sum_{(x,y)} w(x,y) I_x I_y + v^2 \sum_{(x,y)} w(x,y) I_y^2 = [u, v] M \begin{bmatrix} u \\ v \end{bmatrix} \quad \left( M = \sum_{x,y} w(x,y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} \right)$$

flat

edge  
'line'

corner  
'dot'

: E(u, v) 시각화

★ Taylor Series


$$f(x) = p_\infty(x)$$

$$p_n(x) = f(a) + f'(a)(x-a) + \frac{f''(a)}{2!}(x-a)^2 + \dots + \frac{f^{(n)}(a)}{n!}(x-a)^n$$

$$= \sum_{k=0}^n \frac{f^{(k)}(a)}{k!} (x-a)^k$$

: 좌변과 우변이 모든 x에 대해 같은 것이 아니라  $x = a$  근처에서만 성립

④ compute eigenvector and eigenvalues



⑤ use threshold on eigenvalues to detect corners :  $\text{threshold}(R) = \det(M) = k \times (\text{trace}(M))^2$

⑥ Nonmaximal Suppression

- Harris detector는 영상의 평행이동, 회전변화에는 불변(invariant)이고 affine 변화, 조명(illumination) 변화에도 어느 정도는 강인성을 가짐. 하지만 영상의 크기(scale) 변화에는 영향을 받음.

## Chap 4. Feature Descriptors

### • 전통적인 feature descriptors

- ① Image Gradient = binary descriptor : intensity에 강함. 하지만 이동/회전에 약함
- ② Color Histogram : scale/rotate에 강함. 하지만 색이 유사한 물체와 혼동하기 쉬움
- ③ Spatial Color Histogram : deformation에 강함. 하지만 rotate에 약함
- ④ Orientation Normalization

### • GIST Descriptor → Rough spatial distribution of image gradients 구해짐

- ① Compute filter responses ( filter bank of Gabor filters = Directional Edge Detector )

- gabor filter 예시 :  $e^{-\frac{x^2}{2\sigma^2}} \sin(2\pi\omega x)$ ,  $e^{-\frac{x^2}{2\sigma^2}} \cos(2\pi\omega x)$

- ② Divide an image patch on 4x4 cells
- ③ Compute filter response average for each cell : Descriptor 개수 = 4x4xN ( N = filter bank 수)

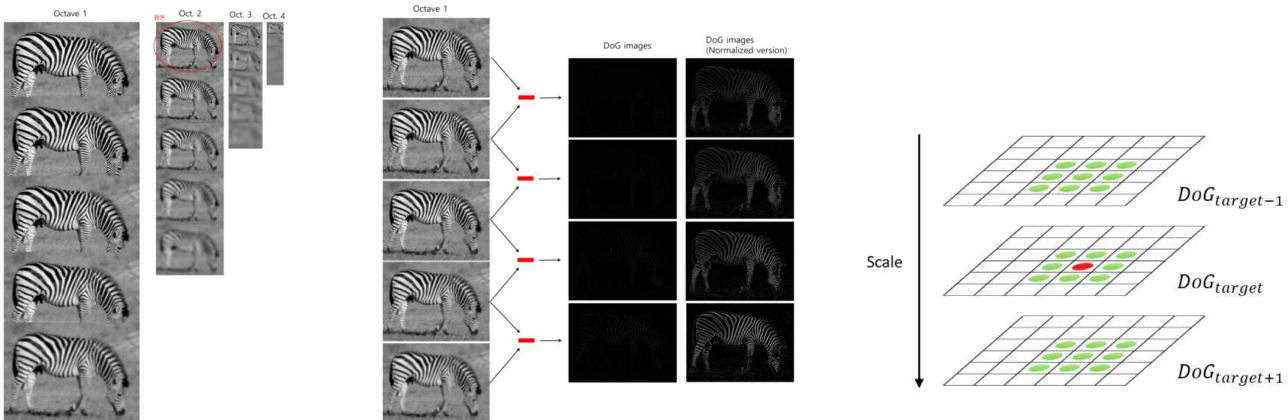
### • SIFT (Scale Invariant Feature Transform)

: feature pointer인 Blob을 찾아(feature detector) 벡터화시킨 feature descriptor 만들기

- 기존의 Harris 코너가 영상의 스케일 변화에 민감한 문제를 해결하기 위하여 Laplacian을 근사한 DoG(Difference of Gaussian)를 기반으로 이미지 내에서 뿐만 아니라 스케일 축(이미지 피라미드)으로도 코너성이 극대점을 찾음
- 스케일에 불변인 특징점을 찾으면 입력 이미지의 스케일이 어떻게 주어지더라도 해당 특징점을 찾아낼 수 있음

### ● Feature Detector


- ① Convolve image with scale-normalized Laplacian(blob filter) at several scales




- ② Find maxima of squared Laplacian response in scale-space
- ③ Eliminate the edge responses based on Harris response function (  $\det(M) = k \times (\text{trace}(M))^2$  )

### ● Feature Description = HOG(Histogram of Oriented Gradients) Descriptor

- ① keypoint 주변의 16개 pixel을 4 x 4 cell로 만들어줌
- ② 한 cell마다 Histogram of Oriented Gradients를 구함
- ③ concatenate and l2 normalization



## Chap 5. 2D Transformations



- Euclidean : rotation + translation
- Similarity : scaling + rotation + translation
- Affine : scaling + shearing + rotation + translation
- projective = homography

Transformation	Matrix	#DoF	Preserves	Icon
translation	$[I t]$	2	orientation	
rigid (Euclidean)	$[R t]$	3	lengths	
similarity	$[sR t]$	4	angles	
affine	$[A]$	6	parallelism	
projective	$[\tilde{H}]$	8	straight lines	

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

translation

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} s_x & 0 & 0 \\ 0 & s_y & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

scaling

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} \cos \Theta & -\sin \Theta & 0 \\ \sin \Theta & \cos \Theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

rotation

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & \beta_x & 0 \\ \beta_y & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

shearing

## Chap 6. Image Homography

### • Solving for Homography matrix

- ① For each correspondence, create 2 x 9 matrix  $A_i$

$$P' = H \cdot P \quad \text{or} \quad \begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \alpha \begin{bmatrix} h_1 & h_2 & h_3 \\ h_4 & h_5 & h_6 \\ h_7 & h_8 & h_9 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

$$x'(h_7x + h_8y + h_9) = (h_1x + h_2y + h_3)$$

$$\rightarrow y'(h_7x + h_8y + h_9) = (h_4x + h_5y + h_6)$$

$$\rightarrow A_i h = 0$$

$$A_i = \begin{bmatrix} -x & -y & -1 & 0 & 0 & 0 & xx' & yx' & x' \\ 0 & 0 & 0 & -x & -y & -1 & xy' & yy' & y' \end{bmatrix}, \quad h = [h_1 \ h_2 \ h_3 \ h_4 \ h_5 \ h_6 \ h_7 \ h_8 \ h_9]^T$$

- ② Concatenate into single  $2n \times 9$  matrix  $A$
- ③ Homogeneous linear least squares problem : Compute SVD of  $A = U\Sigma V^T$
- ④ Store singular vector of the smallest singular value  $h = v_{\hat{}}$
- ⑤ Reshape to get  $H$

### • Robust Feature-based Alignment

- ① Extract feature ( detection & description )
- ② Compute potential matches
- ③ RANSAC ( RANDOM Sample Consensus ) Loop
  - Randomly select a four point correspondences.
  - Compute  $H$
  - Count inliers to the current  $H$
  - Keep  $H$  if largest number of inliers
- ④ Recompute  $H$  using all inliers

★ Least Square Method : 데이터의 residual2의 합을 최소화하도록 모델의 파라미터를 구하는 방법


$Ax = b$ 에서,

- A 역행렬 존재 :  $x = A^{-1}b$

- A 역행렬 존재 X :  $x = A^+(A \text{의 pseudo inverse})b$ , 이는  $\|Ax-b\|$ 를 최소화하는 해임.

-  $A = U\Sigma V^T \rightarrow A \text{의 pseudo inverse}(A^+) = V\Sigma^+U^T$

( $\Sigma^+$  : 원래의  $\Sigma$ 에서 0이 아닌 singular value들의 역수를 취한 후 transpose를 시킨 행렬)



A의 열(column)을 이루는 열벡터의 생성공간(span)인 A의 열공간 col(A)에 포함되어 있는  $\vec{b}$ 를 구하려면  $\vec{a}_1, \vec{a}_2$ 를 얼마만큼 조합해주어야 하는가의 문제

하지만 역행렬이 존재하지 않는다는 것은 span에  $\vec{b}$ 가 존재하지 않는다는 것으로  $\vec{b}$ 와 가장 가까우면서  $\vec{a}_1, \vec{a}_2$ 의 선형결합을 통해 얻을 수 있는 최적의  $\vec{p}$ 는  $\vec{b}$ 를 col(A)에 정사영 시킨 것

- 한계점 : outlier가 포함된 데이터에서는 적용하기 힘든 방법임. 왜냐하면 전체 데이터의 residual2 합을 최소화하기 때문에 outlier의 residual도 같이 줄이려고 하다보면 전혀 잘못된 근사 결과를 낼 수 있음. 따라서, outlier가 존재하는 경우에는 RANSAC, LMedS, M-estimator 등과 같은 robust한 파라미터 추정 방법 사용해야 함

★ Homogeneous Least Square Method

$Ax = 0$ 에서,

- 특이값에 0이 포함된 경우

: 만일 A의 특이값들 중 0이 존재하면 0인 특이값에 대응하는 right singular vector (V의 열벡터)는  $Ax = 0$ 을 만족하는 0이 아닌 해가 된다. 만일, 0의 값을 갖는 특이값이 여러개 존재할 경우에는 대응되는 right singular vector들이 모두  $Ax = 0$ 의 해가 된다. 또한 이들 해의 임의의 일차결합도 역시 해가 된다.

- 특이값이 모두 양수인 경우

: 특이값이 모두 양수인 경우에는  $Ax = 0$ 을 정확히 만족하는 해는  $x = 0$ 을 제외하고는 존재치 않는다. 따라서, 이 경우에는 근사적으로 해를 구해야 하는데  $\|Ax\|$ 를 최소로 하는 근사해는 A의 최소 singular value에 대응하는 right singular vector이다.

★ Eigen Decomposition

: 행렬 A를 자신의 고유벡터들을 열벡터로 하는 행렬과 고유값을 대각원소로 하는 행렬의 곱으로 대각화 분해한 것

- 고유값 분해가 가능하려면 행렬 A가 n개의 일차독립인 고유벡터를 가져야 함

- 대칭행렬( $A^T = A$ )의 고유값 분해 : 항상 고유값 분해가 가능하며, 직교행렬( $A^{-1} = A^T$ )로 대각화가 가능함

★ SVD ( Singular Value Decomposition )

: 정방행렬이 아닌 n x m 행렬에 대해서도 Eigen Decomposition이 가능함

$$A = U\Sigma V^T$$

- U :  $AA^T$ 를 Eigen Decomposition해서 얻어진 orthogonal matrix  $\rightarrow$  U의 열벡터 : A의 left singular vector

- V :  $A^TA$ 를 Eigen Decomposition해서 얻어진 orthogonal matrix  $\rightarrow$  V의 열벡터 : A의 right singular vector


-  $\Sigma$  :  $AA^T, A^TA$ 를 Eigen Decomposition해서 나오는 eigenvalue<sup>2</sup>들을 대각원소로 하는 m x n 직사각 대각행렬 = A의 특이값(singular value)

-  $AA^T, A^TA$ 은 symmetric matrix이므로 Eigen Decomposition이 가능하며 orthogonal matrix로 대각화 가능

-  $AA^T, A^TA$ 의 공통의 고유값  $\sigma_1^2 > \sigma_2^2 > \dots > \sigma_s^2 > 0$ 을 구한 후 이들의 square root를 취한  $\sigma_1 > \sigma_2 > \dots > \sigma_s > 0$ 이 A의 singular value들이고 이들을 대각원소로 하는 m x n 직사각 대각행렬이  $\Sigma$ 임



★ SVD의 기하학적 표현



- orthogonal matrix(  $U, V$  )의 기하학적 의미 : 회전변환(rotate transformation) or reflected 회전변환

$\det(AA^T) = \det(A)\det(A^T) = \det(A)^2 = 1$ 이므로  $\det(A)$ 는 항상 +1 or -1임. 만일  $\det(R)=1$ 라면 이 직교행렬은 회전변환을 나타내고  $\det(R)=-1$ 라면 reflected 회전변환을 나타냄

- diagonal maxtrix(  $\Sigma$  )의 기하학적 의미 : 각 좌표 성분으로의 scale transformation

★ RANSAC 알고리즘의 하이퍼 파라미터 설정

- 파라미터 : 샘플링 과정을 몇 번 ( $N$ ) 반복할 것인지, inlier와 outlier의 경계를 ( $T$ ) 어떻게 정할 것인지

①  $N$

- RANSAC이 성공하기 위해서는  $N$ 번의 시도 중 적어도 한번은 inlier들에서만 샘플 데이터가 뽑혀야 함.

- RANSAC 반복회수를  $N$ , 한번에 뽑는 샘플 개수를  $m$ , 입력 데이터들 중에서 inlier의 비율을  $\alpha$ 라 하면  $N$ 번 중 적어도 한번은 inlier에서만 샘플이 뽑힐 확률  $p = 1 - (1 - \alpha^m)^N$

②  $T$

- inlier들의 residual 분산을  $\sigma$ 라 할 때,  $T = 2\sigma$  or  $3\sigma$  정도로 잡음

- inlier들로만 구성된 실험 데이터들을 획득하고, inlier 데이터들에 대해서 Least Square Method를 적용하여 가장 잘 근사되는 모델을 구함. 이렇게 구한 모델과 inlier들과의 residual ( $r_i = |y_i - f(x_i)|$ )들을 구한 후, 이들의 분산을 구해서, 이에 비례하게  $T$ 를 결정

## Chap 7. Geometric Camera Models

• Pinhole Camera





image plane이 실제론 pinhole 뒤에 있지만, 상이 뒤집어지는 것을 방지하여 pinhole 앞에 있다고 가정할 것임

3D → 2D 될 때,

- 직선, incidence 유지
- 각도, 길이 유지 못함

• Camera Matrix

$$x = PX$$



$$\begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} p_1 & p_2 & p_3 & p_4 \\ p_5 & p_6 & p_7 & p_8 \\ p_9 & p_{10} & p_{11} & p_{12} \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

homogeneous image coordinates      camera matrix      homogeneous world coordinates  
3 x 1                                      3 x 4                                      4 x 1

$$P = \begin{bmatrix} f & 0 & p_x \\ 0 & f & p_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} r_1 & r_2 & r_3 & t_1 \\ r_4 & r_5 & r_6 & t_2 \\ r_7 & r_8 & r_9 & t_3 \end{bmatrix}$$

intrinsic parameters                      extrinsic parameters

- Camera Matrix는 10개의 degrees of freedom가 존재, 만약 skew도 고려한다면 11개

• Extrinsic Parameter

: world 좌표계에서 camera 좌표계로 변환하는 과정에서 필요한 파라미터로 translation과 rotation 변환 포함

• Intrinsic Parameter

: camera 좌표계에서 image 좌표계로 변환하는 과정에서 필요한 파라미터로 이를 거치면 normalized image plane에서의 좌표를 알 수 있음. 이미지 좌표계는 왼쪽 아래에 위치하므로 주점( $p_x, p_y$ )만큼 이동하며, 픽셀의 영향을 해결하기 위해 초점거리(f)를 곱하여 intrinsic matrix를 완성함

+ skew : 카메라 렌즈 왜곡

• Normalized image plane을 구하는 이유

: 동일한 장면을 동일한 위치와 동일한 각도에서 찍더라도 사용한 카메라에 따라서 또는 카메라 세팅에 따라서 서로 다른 영상을 얻게 됨. 따라서, 이러한 요소를 제거한 normalized image plane(z=1)에서 공통된 기하학적 특성을 분석하고 이론을 수립.

• Camera Calibration

$$P = K [ R | t ] = K [ R | -Rc ] = [ M | -Mc ]$$

Given a set of matched points

$$\{ \underset{\substack{\text{point in 3D} \\ \text{space}}}{\mathbf{X}_i}, \underset{\substack{\text{point in the} \\ \text{image}}}{\mathbf{x}_i} \}$$

and camera model

$$\underset{\substack{\text{projection} \\ \text{model}}}{\mathbf{x}} = \underset{\substack{\text{parameters}}}{\mathbf{f}}(\underset{\substack{\text{Camera} \\ \text{matrix}}}{\mathbf{X}; \mathbf{p}}) = \underset{\substack{\text{Camera} \\ \text{matrix}}}{\mathbf{P}} \mathbf{X}$$

$$P = \begin{bmatrix} -f s_x & 0 & x'_c \\ 0 & -f s_y & y'_c \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} \mathbf{R}_{3 \times 3} & \mathbf{0}_{3 \times 1} \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix} \begin{bmatrix} \mathbf{I}_{3 \times 3} & \mathbf{T}_{3 \times 1} \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix}$$

intrinsic                  projection                  rotation                  translation

Find the (pose) estimate of

$$\mathbf{P}$$


- ① 3차원 보정판에서 world 좌표계 좌표 최소 6개를 구함.
- ② Homography matrix를 구하는 방법도 동일하게 camera matrix(P)를 구함.
- ③ camera center  $c$ 를 찾기 위해서 camera matrix SVD 하여 구한 가장 작은 singular vector를 구함 ( $\because PC=0$ ) = translation matrix를 구함
- ④ M를 QR decomposition하여 Intrinsic matrix  $K$ (right upper triangle)와 Rotation Matrix  $R$ (orthogonal)을 구함.

★ 그람슈미트 과정(Gram-Schmidt Process)

: 주어진 벡터들을 이용해서 서로 수직인 벡터들을 만드는 방법

= 주어진 벡터( $v_i$ )들에 대한 직교기저( $u_i$ , orthogonal basis) 또는 정규직교기저(orthonormal basis)를 구하는 과정


$$\begin{aligned} \mathbf{u}_1 &= \mathbf{v}_1, \\ \mathbf{u}_2 &= \mathbf{v}_2 - \text{proj}_{\mathbf{u}_1}(\mathbf{v}_2), \\ \mathbf{u}_3 &= \mathbf{v}_3 - \text{proj}_{\mathbf{u}_1}(\mathbf{v}_3) - \text{proj}_{\mathbf{u}_2}(\mathbf{v}_3), \\ &\vdots \\ \mathbf{u}_k &= \mathbf{v}_k - \sum_{i=1}^{k-1} \text{proj}_{\mathbf{u}_i}(\mathbf{v}_k) \end{aligned}$$



- $\text{proj}_{u_i}(v_j)$  : 벡터  $v_j$ 를 벡터  $u_i$ 에 수직으로 투영한 벡터
- 이렇게 얻어진  $u_1, u_2, \dots, u_k$ 는 서로 수직(orthogonal)이고 벡터공간  $V = \{v_1, v_2, \dots, v_k\}$ 에 대한 직교기저가 된다. 이러한 과정을 그람-슈미트 직교화(orthogonalization)라 부른다.
- 즉, 서로 직교하는 벡터를 구성하기 위해서는 각각이 차지하고 있는 성분 만큼을 빼주어야 한다는 뜻

$$u_2 = a_2 - \text{proj}_{u_1}(a_2)$$

$a_2$ 가 갖고 있는  $u_1$  관련 성분





### ★ QR decomposition

: m x n 행렬 A가 서로 linear independent인 열들을 가지고 있을 때 A는 다음과 같이 분해 가능함.

$$A = QR$$

- Q = m x n 행렬 Q의 열들은 A의 열공간의 orthonormal basis를 구성함
- R = n x n 행렬 R은 양의 대각원소를 가진 upper triangular invertible matrix임

$$\begin{aligned} u_1 &= v_1 \\ u_2 &= v_2 - \left( \frac{v_2 \cdot u_1}{u_1 \cdot u_1} \right) u_1 \\ &\dots \\ u_i &= v_i - \sum_{j=1}^{i-1} \left( \frac{v_i \cdot u_{j-1}}{u_{j-1} \cdot u_{j-1}} \right) u_{j-1} \end{aligned} \quad \Rightarrow \quad \begin{aligned} u_1 &= v_1 \\ u_2 &= v_2 - (v_2 \cdot U_1) U_1 \\ &\dots \\ u_i &= v_i - \sum_{j=0}^{i-1} (v_i \cdot U_{j-1}) U_{j-1} \\ (U_i &= \frac{u_i}{\|u_i\|}) \end{aligned}$$

$$v_1 = u_1 = \|u_1\| U_1 = (v_1 \cdot U_1) U_1$$

$$(\because v_1 \cdot U_1 = \|u_1\| U_1 \cdot U_1 = \|u_1\|, \because U_1 \cdot U_1 = 1)$$

$$\Rightarrow v_2 = (v_2 \cdot U_1) U_1 + u_2 = (v_2 \cdot U_1) U_1 + (v_2 \cdot U_2) U_2 \quad \Rightarrow [v_1 \ v_2 \ v_3] = [U_1 \ U_2 \ U_3] \begin{bmatrix} v_1 \cdot U_1 & v_2 \cdot U_1 & v_3 \cdot U_1 \\ 0 & v_2 \cdot U_2 & v_3 \cdot U_2 \\ 0 & 0 & v_3 \cdot U_3 \end{bmatrix}$$

$$\begin{aligned} v_3 &= (v_3 \cdot U_1) U_1 + (v_3 \cdot U_2) U_2 + u_3 \\ &= (v_3 \cdot U_1) U_1 + (v_3 \cdot U_2) U_2 + (v_3 \cdot U_3) U_3 \end{aligned}$$

• Ames Room Illusion : anlg과 pallel한 선들의 정보를 잃으므로 착시 효과를 볼 수 있음


### • Depth of Field

- len가 focus하는 필름의 부분으로 in focus, 그 외의 부분은 circle of confusion이라는 표현을 씀
- 조리개를 조절하여 aperture 사이즈가 줄어들면, in focus되는 크기가 커짐
- 하지만, light의 양이 줄어들어 exposure 시간을 늘려야 함



### • Field of View( FOV )

- focal length와 camera retina의 사이즈에 영향을 받음
- $FOV = \tan^{-1}(\frac{d}{2f})$
- 따라서, small f → large FOV : camera close to object  
large f → small FOV : camera far to object




### • Orthographic Camera

- Perspective Camera : 사물에 대해 원근감과 공간감을 잘 표현함

$$P = \begin{bmatrix} f & 0 & p_x \\ 0 & f & p_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

- Orthographic Camera : 사물에 대해서 원근감과 공간감 없이 표현함

$$P = \begin{bmatrix} f & 0 & p_x \\ 0 & f & p_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & Z_o \end{bmatrix}$$



A와 B가 크기가 같아도 A가 더 가깝기 때문에 더 크게 표현  
B를 A의 위치에 이동시키면서 projection 하므로 원근감이 사라짐

## Chap 8. Two View Geometry

### • Triangulation

Given a set of (noisy) matched points


$$\{x_i, x'_i\}$$

and camera matrices

$$P, P'$$

Estimate the 3D point

$$X$$



$$PX = x$$

$$P^{-1}PX = P^{-1}x$$

$$X = P^{-1}x$$

만약, P의 역행렬이 존재하지 않는다면, pseudo-inverse를 통해서 P의 역행렬을 근사하도록 함

- x와 x'이 교차하지 않아 x를 구할 수 없는 경우가 생기는 이유

- ① x, x'는 image 좌표이므로 discrete하게 구한 점이므로 error를 포함하고 있음
- ② camera matrix P와 P'는 estimation하여 구했을 시 error를 포함하고 있음

- 방향이 같이 두 벡터를 Cross Product하면 0이 되는 성질 이용

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} = \alpha \begin{bmatrix} p_1 & p_2 & p_3 & p_4 \\ p_5 & p_6 & p_7 & p_8 \\ p_9 & p_{10} & p_{11} & p_{12} \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} = \alpha \begin{bmatrix} -p_1^\top & -p_2^\top & -p_3^\top \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} = \alpha \begin{bmatrix} p_1^\top X \\ p_2^\top X \\ p_3^\top X \end{bmatrix}$$


Using the fact that the cross product should be zero

$$x \times PX = 0$$

### ★ Cross Product

takes two vectors and returns a vector perpendicular to both

$$c = a \times b$$



$$a \times b = \begin{bmatrix} a_2b_3 - a_3b_2 \\ a_3b_1 - a_1b_3 \\ a_1b_2 - a_2b_1 \end{bmatrix}$$

cross product of two vectors in the same direction is zero

$$a \times a = 0$$

$$c \cdot a = 0$$

$$c \cdot b = 0$$

$$\begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \times \begin{bmatrix} p_1^\top X \\ p_2^\top X \\ p_3^\top X \end{bmatrix} = \begin{bmatrix} yp_3^\top X - p_2^\top X \\ p_1^\top X - xp_3^\top X \\ xp_2^\top X - yp_1^\top X \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$


좌, 우 이미지 좌표 대입

$$\begin{bmatrix} yp_3^\top - p_2^\top \\ p_1^\top - xp_3^\top \\ y'p_3^\top - p_2^\top \\ p_1^\top - x'p_3^\top \end{bmatrix} X = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$


- 마지막 식은 위의 두 식에 dependent하므로 위의 두 식만을 이용함.

### • Epipolar Geometry

: 동일한 장면에 대한 영상을 다른 두 지점에서 획득했을 때, 영상 A와 B의 매칭 간의 기하학적 관계를 다루는 것



### • Epipolar Constraint



- A의 영상좌표 x로부터 대응되는 B의 영상좌표 x'을 유일하게 결정할 수는 없지만 x'이 지나는 직선인 epipolar line l'은 유일하게 결정할 수 있음

- 한 영상좌표로부터 다른 영상에서의 대응되는 epipolar line을 계산해주는 변환행렬이 Fundamental Matrix, Essential Matrix 임

• Essential Matrix : maps a point to a line (3x3)

- 유도

rigid motion                      coplanarity

$$\mathbf{x}' = \mathbf{R}(\mathbf{x} - \mathbf{t}) \quad (\mathbf{x} - \mathbf{t})^\top (\mathbf{t} \times \mathbf{x}) = 0$$

$$(\mathbf{x}'^\top \mathbf{R})(\mathbf{t} \times \mathbf{x}) = 0$$

$$(\mathbf{x}'^\top \mathbf{R})([\mathbf{t}_\times] \mathbf{x}) = 0$$


$$\mathbf{x}'^\top (\mathbf{R}[\mathbf{t}_\times]) \mathbf{x} = 0$$

camera 사이의  
관계가 E에 encoding

$$\mathbf{x}'^\top \mathbf{E} \mathbf{x} = 0$$

$[\mathbf{t}]_\times \mathbf{R}$ 은  $\mathbf{t}$ 와  $\mathbf{R}$ 과의 외적을 의미하는게 아니라 먼저  $\mathbf{R}$ 로 회전을 시킨 후 다음에  $\mathbf{t}$ 와 외적을 시키는 일련의 변환을 의미함.

$$\mathbf{E} \mathbf{x} = [\mathbf{t}_\times] \mathbf{R} \mathbf{x} = \mathbf{t} \times (\mathbf{R} \mathbf{x})$$



- 성질

Longuet-Higgins equation       $\mathbf{x}'^\top \mathbf{E} \mathbf{x} = 0$


Epipolar lines       $\mathbf{x}^\top \mathbf{l} = 0$        $\mathbf{x}'^\top \mathbf{l}' = 0$   
 $\mathbf{l}' = \mathbf{E} \mathbf{x}$        $\mathbf{l} = \mathbf{E}^\top \mathbf{x}'$

Epipoles       $\mathbf{e}^\top \mathbf{E} = 0$        $\mathbf{E} \mathbf{e} = 0$

$$ax + by + c = 0 \quad \text{in vector form} \quad \mathbf{l} = \begin{bmatrix} a \\ b \\ c \end{bmatrix}$$

If the point  $\mathbf{x}$  is on the epipolar line  $\mathbf{l}$  then

$$\mathbf{x}^\top \mathbf{l} = 0$$



• Fundamental Matrix

: Essential matrix가 가진 calibrated cameras 가정이 없어진 것으로, intrinsic parameter 요소가 포함된 matrix

$$\hat{\mathbf{x}}'^\top \mathbf{E} \hat{\mathbf{x}} = 0$$

The Essential matrix operates on image points expressed in normalized coordinates (points have been aligned (normalized) to camera coordinates)

$$\hat{\mathbf{x}}' = \mathbf{K}^{-1} \mathbf{x}' \quad \hat{\mathbf{x}} = \mathbf{K}^{-1} \mathbf{x}$$

camera point      image point

Writing out the epipolar constraint in terms of image coordinates

$$\mathbf{x}'^\top \mathbf{K}'^{-\top} \mathbf{E} \mathbf{K}^{-1} \mathbf{x} = 0$$

$$\mathbf{x}'^\top (\mathbf{K}'^{-\top} \mathbf{E} \mathbf{K}^{-1}) \mathbf{x} = 0$$

$$\mathbf{x}'^\top \mathbf{F} \mathbf{x} = 0$$

- F는 rank = 2인 singular matrix이고 DOF = 7

- E는 rank = 2인 singular matrix이고 DOF = 5

• (Normalized) Eight-Point Algorithm : Fundamental Matrix 구하는 법

① Normalize points : 이미지의 크기가 클 경우, (x,y)의 범위가 커져서 matrix A에서  $\mathbf{x}\mathbf{x}'$ ,  $\mathbf{x}\mathbf{y}$  같은 항들의 중요도가 높아지므로 normalize를 통해서 scale을 맞춰줌

② Construct the M x 9 matrix A

$$\begin{bmatrix} x_1 x'_1 & x_1 y'_1 & x_1 & y_1 x'_1 & y_1 y'_1 & y_1 & x'_1 & y'_1 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_M x'_M & x_M y'_M & x_M & y_M x'_M & y_M y'_M & y_M & x'_M & y'_M & 1 \end{bmatrix} \begin{bmatrix} f_1 \\ f_2 \\ f_3 \\ f_4 \\ f_5 \\ f_6 \\ f_7 \\ f_8 \\ f_9 \end{bmatrix} = \mathbf{0}$$

③ Find the SVD of A

④ Store singular vector of the smallest singular value  $\mathbf{F} = \mathbf{v}_{\hat{}}$

⑤ Enforce rank 2 constraint on F ( F의 마지막 singular value를 0으로 바꿈 )

: point( DOF = 0 ) → line( DOF = 1 ) mapping이므로 3개였던 constraint를 2개로 relax 해주기 위해서 rank-2 constraint 적용

⑥ Un-normalize F

• 주의할 점

: F와 E의 스케일(scale)까지는 결정할 수 없음. 물체와 카메라가 존재하는 공간 전체를 확대하거나 축소해도 동일한 이미지를 얻기 때문에 이미지만 가지고는 스케일을 알 수 없다는 것을 의미함. 즉, 가까이에 있는 작은 물체를 찍거나 멀리 있는 큰 물체를 찍어도 같은 영상을 얻을 수 있다는 것을 의미함.

★ Singular Matrix

$$AX=B \rightarrow X=A^{-1}B$$

: 역행렬은 정방행렬에 대해서만 정의되며, 역행렬은 determinant(행렬식)  $\det(A) = 0$ 이면 존재하지 않음.  
 이때, 역행렬이 존재하지 않는 A를 singular matrix라 함.

★ Determinant

$$x' = Ax$$

: 행렬 A는 입력좌표 x를 x'으로 변환시켜주는 선형변환(linear transformation)으로 해석 가능  
 이러한 관점에서  $\det(A)$ 는 선형변환의 스케일(scale) 성분을 나타내는 값으로  $P' = AP$ 와 같이 도형 P가 선형변환 A에 의해 P'으로 변환되었을 경우, 다음 수식이 성립한다.  
 - 면적( $P'$ ) =  $|\det(A)| \times$  면적( $P$ ) : 2D의 경우  
 - 부피( $P'$ ) =  $|\det(A)| \times$  부피( $P$ ) : 3D의 경우  
 이때,  $\det(A) > 0$ 이면 도형의 방향(orientation)이 보존되고  $\det(A) < 0$ 이면 도형의 방향이 보존되지 않음.  $\det(A) = 0$ 이면, 평면은 직선으로 삼차원 모형은 평면으로 변한다.

Chap 9. Stereo

• Rectified Images

When this relationship holds:

$$R = I \quad t = (T, 0, 0)$$

$$x'^T E x = 0, \quad E = [t_x] R$$

$$E = [t_x] R = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & -T \\ 0 & T & 0 \end{bmatrix}$$

- baseline과 각각의 image plane이 평행함
- camera center가 같은 height에 위치함
- focal lengths가 같음
- epipolar line이 image의 x축에 나란함

$$S = \begin{bmatrix} 0 & -T_z & T_y \\ T_z & 0 & -T_x \\ -T_y & T_x & 0 \end{bmatrix}$$


$$(u' \ v' \ 1) \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & -T \\ 0 & T & 0 \end{bmatrix} \begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = 0 \quad (u' \ v' \ 1) \begin{pmatrix} 0 \\ -T \\ T_v \end{pmatrix} = 0 \quad T_v' = T_v$$

• Rectification : epipole at infinity

- ① Essential Matrix E 구하기 ( 8-point algorithm )
- ② Decompose E into R and T

■ For a given essential matrix

$$SVD(E) = U \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} V^T$$



$$P = \begin{bmatrix} f & 0 & p_x \\ 0 & f & p_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} r_1 & r_2 & r_3 & t_1 \\ r_4 & r_5 & r_6 & t_2 \\ r_7 & r_8 & r_9 & t_3 \end{bmatrix}$$

intrinsic parameters                  extrinsic parameters

camera matrix에서 intrinsic parameter는 essential matrix에서 고려하지 않아도 됨


■ If we assume that  $P_1 = [I | 0]$ , there are four possible choices for the second camera matrix  $P_2$

$$\begin{aligned} P_2 &= [UWV^T | +u_3] \\ P_2 &= [UWV^T | -u_3] \\ P_2 &= [UW^T V^T | +u_3] \\ P_2 &= [UW^T V^T | -u_3] \end{aligned} \quad W = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$u_3 = U(0, 0, 1)^T$ : the last column vector of U

4가지 경우의 수 P 중 depth값이 모두 양수인 case1와 같은 상황만 해로 가질 수 있음.

- $T = e = u_3$
- $R = P[:2, :2]$



③  $R_{rect}$ 를  $e(=T)$ 를 통해 구하기

Let  $R_{rect} = \begin{bmatrix} r_1^T \\ r_2^T \\ r_3^T \end{bmatrix}$  Given: epipole  $e$  (using SVD on  $E$ ) (translation from  $E$ )

$r_1 = e_1 = \frac{T}{\|T\|}$  epipole coincides with translation vector

$r_2 = \frac{1}{\sqrt{T_x^2 + T_y^2}} \begin{bmatrix} -T_y & T_x & 0 \end{bmatrix}$  cross product of  $e$  and the direction vector of the optical axis

$r_3 = r_1 \times r_2$  orthogonal vector

- singular vector of the smallest singular value  $e = v_l = T$

- optical axis =  $[0, 0, 1]$


-  $[T_x, T_y, T_z] \times [0, 0, 1] = [T_y, -T_x, 0]$

④  $R_1 = R_{rect}$ ,  $R_2 = RR_{rect}$

⑤ 회전시키기 :  $[x'_r, y'_r, z'_r] = R_1[x_r, y_r, z_r]$ ,  $[x'_l, y'_l, z'_l] = R_2[x_l, y_l, z_l]$

⑥ Rectified point :  $p_r = \frac{f}{z'_r}[x'_r, y'_r, z'_r]$ ,  $p_l = \frac{f}{z'_l}[x'_l, y'_l, z'_l]$

### Disparity and Depth




$$\text{disparity } d = \frac{f \times b}{Z}$$

$$\text{depth } Z = \frac{f \times b}{d}$$

disparity : 좌/우 이미지에서 matching point의 위치 차이

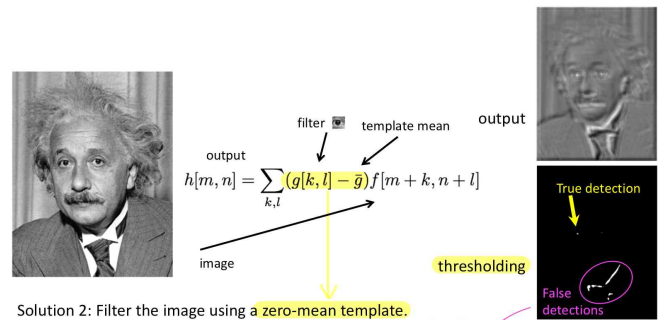
- Rectified된 이미지에서 disparity를 구해야 계산량이 적어짐

### Find the template : 3가지 방법



Solution 1: Filter the image using the template as filter kernel.


What went wrong?  
Increases for higher local intensities.



Solution 2: Filter the image using a zero-mean template.


음수 값도 가지므로 흰색에서 0보다 크지 않음  
음수인 부분에 0이 곱해지고  
양수인 부분에 1이 곱해질 경우

What went wrong?  
Not robust to high-contrast areas



Solution 3: Use sum of squared differences (SSD).

What could go wrong?  
Not robust to local intensity changes




Solution 4: Normalized cross-correlation (NCC).



• Correspondence Search

: 한 점에 대해서 epipolar line에서 searching 하는 방법

- 실패하는 상황 : Textureless surfaces, occlusions, repetition, non-lambertian surfaces, specularities



occlusion 예시


• Effect of Window size

- small window : more detail BUT, more noise
- larger window : smoother disparity maps BUT, less detail and fails near boundaries

• 향상된 Stereo Matching 방법

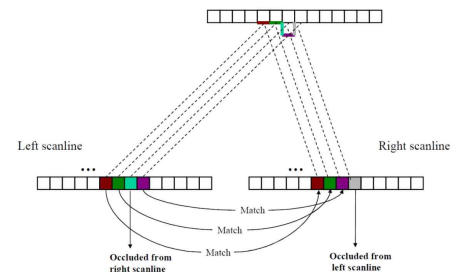
• Disparity Space Image (DSI) : global matching 방법

: epipolar line = scanline의 dissimilarity value를 조사한 후, non-local한 correspondence constraints 영향을 주기 위해서 dynamic programming을 통해 matching point를 찾음




- Correspondence Constraints

- ① Uniqueness Constraint : matching 점은 하나 또는 0개가 되어야 함.
- ② Ordering Constraint : occlusion이 일어나지 않은 점에 한해서는 매칭점의 order이 좌/우 이미지에서 동일해야함.



- Dynamic Programming : Shortest paths for scanline stereo



★ Dynamic Programming

: 전체 문제를 작은 문제로 단순화한 다음 점화식으로 만들어 재귀적인 구조를 활용해서 전체 문제를 해결하는 방식

• Block Matching : local matching 방법

: 인접한 pixel간 depth는 smooth하게 변한다는 가정을 두고 disparity 구함

- Energy Function

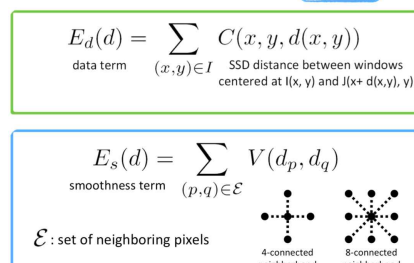
$$E(d) = E_d(d) + \lambda E_s(d)$$

- data term = block matching result

: want each pixel to find a good match in the other image

- Smoothness term = smoothness function

: Adjacent pixels should (usually) move about the same amount



$$V(d_p, d_q) = |d_p - d_q|$$

L1 distance



$$V(d_p, d_q) = \begin{cases} 0 & \text{if } d_p = d_q \\ 1 & \text{if } d_p \neq d_q \end{cases}$$

"Potts model"

